

LORIS 规则学习方法说明

错误驱动的分阶段规则发现 (ML $\rightarrow$ FN-Add $\rightarrow$ FP-Remove $\rightarrow$ 传播)

LORIS Pipeline

2026-06

1 概述

LORIS 在一个已训练的多标签分类器集成之上，自动学习符号规则来修正其错误并支持人机协同传播。规则发现被组织为四个**累计阶段**：每个阶段在前序所有阶段的累计预测 P_{i-1} 之上学习，并产出与其职责相符的结论算子（+ 加标签 / - 删标签 / 传播）。最终预测由 Chase 推理给出，语义为

$$\text{pred} = \text{pos} \wedge \neg \text{neg}, \quad \text{add 规则写入 pos, remove 规则写入 neg.}$$

该顺序与应用语义保证：先用 ML 集成从空白重建标签，再用文本谓词召回漏判 (FN)，再删除误判 (FP)，最后做（人机协同的）相似/标签传播。

阶段	学习内容	规则形式 (体 $\rightarrow$ 算子)	学习基准	开关
0	ML 集成 ADD	<code>ml_thresh(L) $\rightarrow$ +L</code> (单/多模型 AND)	$\emptyset \rightarrow P_0$	<code>stage0_ml</code>
1	FN$\rightarrow$ADD (新)	<code>match/freq(P) [$\wedge$ ml(L)] $\rightarrow$ +L</code>	$P_0 \rightarrow P_1$	<code>stage1_fn_add</code>
2	FP $\rightarrow$ REMOVE	<code>match/freq(P) $\wedge$ ml $\rightarrow$ -L</code>	$P_1 \rightarrow P_2$	<code>stage2_fp_remove</code>
3	复合传播	<code>label(A)$\wedge$text(P)$\rightarrow$ +B; sim$\wedge$label$\wedge$text</code>	$P_2 \rightarrow \text{final}$	<code>stage3_propagation</code>

设计动机. 旧流程在 `track1_baseline=blank` 下只学到 ML 规则：文本谓词被硬编码成只能做 REMOVE（结论算子按阶段固定），没有 `pattern $\rightarrow$  +L` 的 ADD 通道；FN 判别 n-gram 只被塞进传播轨；传播以模型自身标签为种子（循环无源）。本设计修复了这些结构缺陷。

2 谓词目录

规则体是谓词的合取式。涉及的谓词类型：

- `MatchPredicate(attr, P)`: 文档字段 `attr` 含正则/词 `P`。
- `FreqPredicate(attr, P, op,  $\eta$ )`: `P` 在 `attr` 中出现次数 `op  $\eta$` ($\geq$ / $\leq$)。
- `CooccurPredicate(P,Q)` / `BeforePredicate(P,Q)`: 两词共现 / 前后序。

- `MLThresholdPredicate(model, L, t)`: 模型对标签 L 的概率 $\geq t$ 。
- `LabelPredicate(A, op)`: 文档当前标签集满足条件 (如 $A \in x.\text{lbl}$)。
- `SimPredicate(threshold)`: 存在相似度 $\geq \text{threshold}$ 的邻居 y 。
- `GroupPredicate` / 比较结论 $x.\text{lbl}=y.\text{lbl}$: 共属/标签集传播。

3 各阶段详解

Stage 0 ——ML 集成 ADD (基线 P_0)

用 `inject_ml_baseline_rules` 生成 `ml_thresh(model, L, t)  $\rightarrow$  +L`, 包括单模型阈值与多模型 AND 组合 $(p_a \geq t_a) \wedge (p_b \geq t_b)$ 。多模型交集要求两个强而互补的模型 (如 `encoder + tfidf`) 才有效; 这是宏 F1 增益的主要来源。保留多样化模型池 (含 `tfidf`), 不要用 `--model_pool embedding` 丢弃 `tfidf`——否则集成退化为 `encoder` 单模型, 差距在 Stage 0 即已产生。

Stage 1 ——FN $\rightarrow$ ADD 文本召回 (新增; $P_0 \rightarrow P_1$)

对每个标签 L , 取假阴区 (模型说“非 L ”但真值为 L), 用 TF-IDF 挖掘判别性 **n-gram** (区分 FN 文档与真负文档), 直接合成

$$\text{match}(P) [\wedge \text{ml_thresh}(\text{model}, L, t_{\text{low}})] \rightarrow +L.$$

这是直接合成 (非随机 BO): 候选只来自错误本身 (每标签数个), 不产生候选爆炸。低阈值 ML 守卫 t_{low} 用于在“模型对 L 完全否定”时抑制误加。保留条件: 验证集 `precision` $\geq$ `fn_add_min_val_prec` (默认 0.70) 且改进数 $\geq$ 下限; 每标签至多 `stage1_max_rules_per_label` 条。实现 `_synthesize_fn_add_rules(loris/pipeline/steps.py)`。实例 (*BGC*): `match(secrets)  $\wedge$  ml(encoder, Literary Fiction, 0.2)  $\rightarrow$  +Literary Fiction; match(god)  $\wedge$  ml(encoder, Fantasy, 0.05)  $\rightarrow$  +Fantasy。`

Stage 2 ——FP $\rightarrow$ REMOVE 精度修剪 ($P_1 \rightarrow P_2$)

在累计 P_1 之上, 取假阳区, 用 `_extract_error_driven_predicates(mode="fp")` 得到 FP-判别谓词, 经 Optuna BO + `batch_select` 选出 `match/freq(P)  $\wedge$  ml  $\rightarrow$  -L`。打分基准为 P_1 : n_{improved} = 删除的真 FP, n_{worsened} = 误删的 TP; 硬门槛 `raw precision` $\geq$ 0.85 (弱标签 0.65), $n_{\text{improved}} \geq 2$ 。每标签至多 `stage2_max_rules_per_label` 条。实例 (*BGC*): `freq( $\$ \cdots \$$ )  $\leq 2 \wedge$  ml(encoder, History, 0.25)  $\rightarrow$  -Historical Fiction。`

Stage 3 ——复合传播 (人机协同; $P_2 \rightarrow \text{final}$)

学习复合传播规则 (不允许裸标签共现):

$$\text{label}(A) \wedge \text{text}(P) \rightarrow +B, \quad \text{sim}(x, y) \wedge \text{label}(\tau \in y.\text{lbl}) \wedge \text{text}(P) \rightarrow +\tau, \quad x.\text{lbl} = y.\text{lbl}.$$

关键：以 **GT/oracle 标签为种子学习** (`prop_label_source=gt`)，而非模型自身标签——因为传播的价值在**人给一个正确种子即可向邻居正确扩散**的主动场景。`prop_require_text` 默认开启，过滤掉无文本谓词的裸 `sim^label` 与裸共现规则（保留 `x.lbl=y.lbl` 比较规则）。实例 (*BGC*): `label(Self-Improvement) ^ match(form) → +Personal Growth`。

预期. 由于 P_2 已是高精度，零预算下 Stage 3 规则很少甚至为 0——这是强分类器下的固有现象，并非 bug；传播只有在人提供种子后（RILL 预算扫描）才显著见效，这恰是”传播需要人机协同”的正面证据。

4 谓词与规则数目分配（防”富谓词更差”）

”更多谓词反而更差”的根因是**候选爆炸稀释固定搜索预算**（旧 B 运行 3645 候选/簇、30 trials $\Rightarrow$ 仅探 0.8%）。三层分配：

1. **候选(谓词)按类型封顶**: `_select_top_predicates` 用 `per_type_top_k` (默认 60)/`predicate_top_k` (默认 240) 按 `phi×coverage` 排序，对每类 {Match/Freq/Cooccur/Before/Sim} 限额，富化无法挤占其它类型。Stage 1/2 的错误驱动候选本就是**小而精准**的每标签集合。
2. **规则(输出)按阶段 × 标签配额**: `stageN_max_rules_per_label` (默认 3/3/2), 配合 `top_n_rules/top_per_ty` 得到”ML 基线 + 少量 FN-add + 少量 FP-remove + 少量传播”的均衡分布。
3. **搜索预算分配**: 传播 BO 仅用 `prop_trial_frac` 比例的 trials; Stage 1/2 为直接合成不耗 BO 预算。

每阶段的”按类型候选数 / 按类型与标签规则数 / $\Delta F1$ ”写入 `staged_pipeline_logs.json`，便于单次运行即可调参与诊断。

5 传播 & RILL 人机协同主动学习

`RILLController` (`loris/rill/rill.py`) 在测试时执行主动回路：以规则依赖图估计**影响力**，向 `GroundTruthOracle` (模拟人) 查询最有信息量的未标注文档，注入其标签后增量 Chase，经规则 + 相似图传播。我们在测试集上做**人工标注预算扫描** (`--rill_budget_sweep 0,10,25,50,100,200`)，输出 `rill_budget_sweep.json`（每预算的 micro/macro 与查询数）。

连通性保证. `auto_threshold_bins` 新增 `min_avg_degree` 下限 (`sim_min_avg_degree`, 默认 20): 若所有阈值过稀疏，则补一个达到该平均度的较密阈值（即便超过常规上限——RILL 钳制种子，雪崩有界），使种子有实际传播路径；`build_sim_graph` 对该图放宽 `max_avg_degree`。运行时记录每阈值平均度并在扫描前断言至少一个阈值达标。**富化相似谓词**: `--sim_target_degrees` 可注入更细/更密的目标平均度分箱（默认空 = 5, 10, 20, 40，黄金中性），供传播 BO 选择更细粒度的相似阈值；可在端到端 A/B 中度量其增益。**扫描可行性**: 相似图为 $O(n^2)$ 、逐查询影响力为 $O(|U|)$ ，故扫描按 `--rill_sweep_max_docs` (默认 3000) 定种子子采样测试集（BGC 全集 33k 不可行）。

可复现性(确定性). 规则发现的确定性由以下保证:(i) 嵌入子采样与 BO 的固定随机种子;(ii) 黄金测试中固定 `PYTHONHASHSEED`; (iii) 确定的候选排序——正则锚点抽取改为返回 `sorted(anchors)`

(原 `list(set(...))` 的集合迭代序依赖哈希种子，会渗入并列 top- k 谓词与规则的选择)。此外移除了不可构造的遗留 minus 标签算子（标签删除是结论 `consequence_op="remove"`，非体谓词）。

6 诚实报告：逐条边际贡献

旧 `analyze_rule_corrections` 把每条规则孤立地贴到原始基准上评估，导致 remove 在空白基准上恒显示 0（方法假象）。新版改为**留一边际** (leave-one-out)：先算全规则集的累计预测，再逐条移除该规则重算，

$$\text{marginal_F1}(r) = \text{F1}(\text{全部规则}) - \text{F1}(\text{全部} \setminus \{r\}).$$

这样”修正某 ADD 引入的 FP”的 REMOVE 会显示为正贡献。输出按**阶段**汇总到 `rule_analysis.txt` 与 `rule_analysis_stage_rollup.json`。

7 超参表

参数	默认	含义
<code>stage0_ml / stage1_fn_add</code>	True	启用 Stage 0 ML 基线 / Stage 1 FN→ADD
<code>stage2_fp_remove / stage3_propagation</code>	True	启用 Stage 2 REMOVE / Stage 3 传播
<code>fn_add_min_val_prec</code>	0.70	FN→ADD 规则的验证集精度下限
<code>fn_add_top_k_per_label</code>	8	Stage 1 每标签挖掘的 FN 判别谓词数
<code>fn_add_ml_guard</code>	True	是否给 FN→ADD 文本体加低阈值 ML 守卫
<code>stage1/2/3_max_rules_per_label</code>	3/3/2	各阶段每标签规则配额
<code>prop_require_text</code>	True	传播规则必须含文本谓词（禁裸共现）
<code>prop_label_source</code>	track1	传播 BO 的种子标签来源 (gt/track1/model; CLI 默认 track1, 传播实验推荐 gt)
<code>prop_trial_frac</code>	0.5	传播 BO 占 <code>max_trials</code> 的比例
<code>per_type_top_k</code>	60	每谓词类型候选封顶
<code>predicate_top_k</code>	240	每簇候选谓词总封顶
<code>sim_min_avg_degree</code>	20	相似图连通性下限（平均邻居数）
<code>sim_target_degrees</code>	""	相似图阈值分箱的目标平均度（富化相似谓词）；空 = 默认 5,10,20,40，例 3,5,8,12,20,30,40,60
<code>rill_budget_sweep</code>	""	测试时 RILL 人工预算扫描，如 0,10,25,50,100,200
<code>rill_sweep_max_docs</code>	3000	RILL 扫描的测试文档上限（相似图为 $O(n^2)$ ，全集如 BGC 33k 不可行，故定种子采样）
<code>max_trials</code>	30/200	每簇 Optuna 试验数

参数	默认	含义
min_corr_prec	0.65	batch_select 修正精度下限
min_n_changes / min_rule_fires	1/1	规则最小改动/触发数（自适应放宽）
sim_cascade_rounds	3	传播 BO 中相似级联模拟轮数

8 实验结果

端到端运行：BGC（12k 训练、30 标签、8k 测试）与 AAPD（15k、30 标签）；blank 基线、pattern_mode=sim、模型池含 encoder 与 tfidf、四阶段全开、max_trials=30。

总体指标（测试集）

数据集	基线 micro / macro	模型 + 规则 micro / macro	Δ micro / Δ macro	规则数
BGC（本方法）	0.766 / 0.571	0.780 / 0.694	+0.014 / +0.123	77
BGC（旧 A，胜者）	0.767 / 0.560	0.781 / 0.689	+0.014 / +0.129	70
AAPD（本方法）	0.682 / 0.546	0.644 / 0.632	-0.038 / +0.086	94

BGC 上宏 F1 由旧最佳 0.689 提升到 **0.694**，micro 持平（ ≈ 0.78 ）。

规则分布（已修复”只有 ML 规则”）

数据集	Stage0 ML	Stage1 FN-add	Stage2 remove	Stage3 prop	文本谓词数
BGC	60	2	14	1	13（6 Match + 7 Freq）
AAPD	76	1	16	1	7 Match

现已学到 ml+text 的 ADD、text+ml 的 REMOVE、label+text 的复合传播三类规则（见各阶段实例），不再是清一色 ML 规则。

逐阶段留一边际（测试宏 F1）与诚实评估

BGC：Stage0 +0.490、Stage1 -0.000、Stage2 +0.000、Stage3 0；AAPD：Stage0 +0.339、Stage1 +0.000、Stage2 +0.002、Stage3 0。即：增益仍由 ML 集成主导；文本/删除/传播规则虽被成功学到且语义合理，但在强分类器上的测试边际接近 0——这与”强基线下传播/纠错头部空间很小”的预期一致。

RILL 人工预算扫描

AAPD 各预算 (0-200) $\text{micro} \approx 0.591$ 、 $\text{macro} \approx 0.631$ 且**查询数为 0**、曲线持平——因为 Stage 3 仅产出约 1 条传播规则、无 `sim` 规则，故无传播路径可供主动回路利用（连通性下限保证了图够密，但缺少使用该图的 `sim` 规则）。BGC 预算 0（仅规则） micro 0.778、 macro 0.693。

结论与后续

- **已达成**：四阶段流程跑通，学到均衡且可解释的规则混合；BGC 宏 F1 提升、`micro` 持平；逐阶段贡献可量化、可消融。
- **诚实局限**：在强 ML 基线上，文本/删除/传播规则的测试边际仍 ≈ 0 ；要让传播真正见效，需 Stage 3 产出足量 `sim` 复合规则（可降低 `sim` 阈值或放宽 `prop` 门槛），并在有种子的 RILL 场景评估。AAPD 的 `micro` 下降源于 `blank+global_macro` 目标偏向宏 F1，可按需切换 `batch_metric_mode`。